lab09

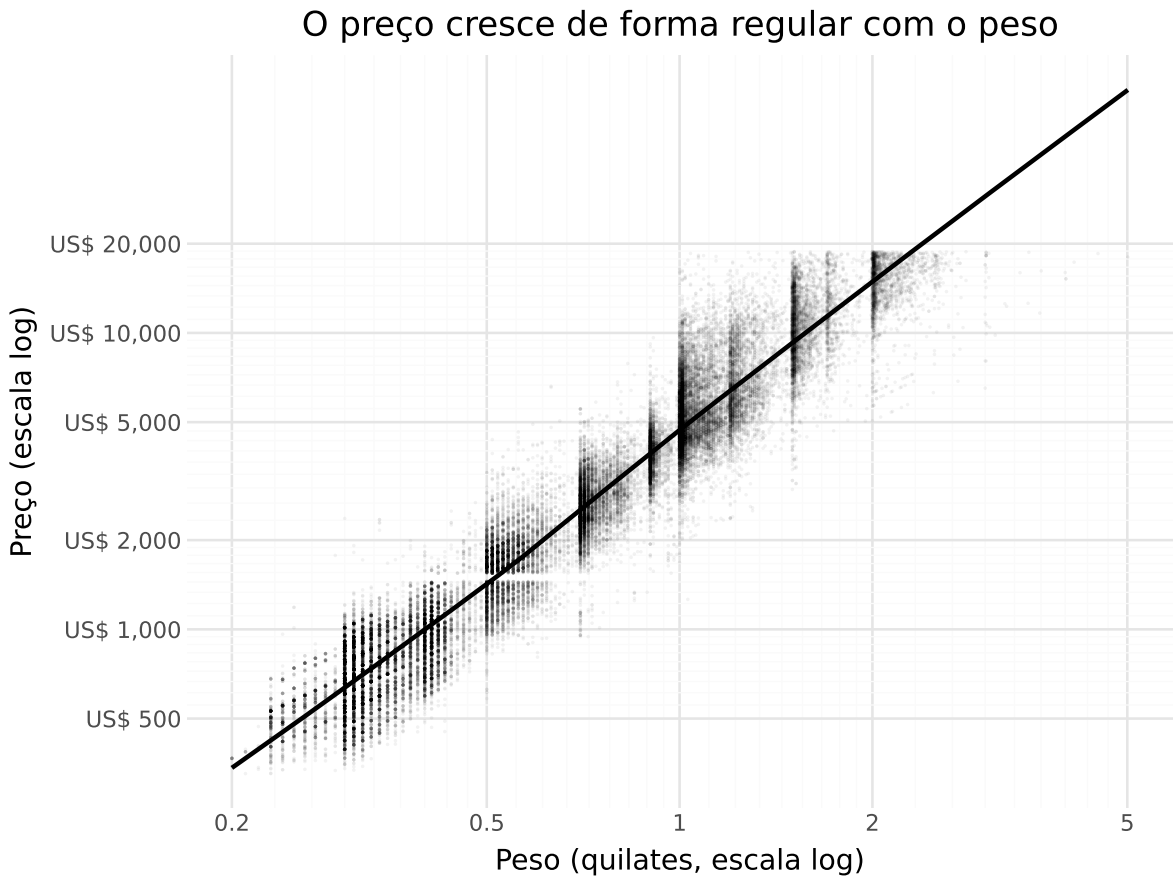
```
library(reticulate)
py_require(c("pandas", "numpy", "plotnine", "statsmodels", "scipy"))
```

1.

```
import numpy as np
import pandas as pd
from plotnine import *
from plotnine.data import diamonds
df = diamonds.copy()
```

2.

```
p1 = (ggplot(df, aes("carat", "price"))
    + geom_point(alpha=0.05, size=0.8, stroke=0)
    + geom_smooth(method="lowess", color="black", se=False)
    + scale_x_log10(breaks=[0.2, 0.5, 1, 2, 5])
    + scale_y_log10(breaks=[500, 1000, 2000, 5000, 10000, 20000], labels=lambda l: [f"US$ {r
    + labs(x="Peso (quilates, escala log)", y="Preço (escala log)", title="O preço cresce de
    + theme_minimal())
p1.show()
```

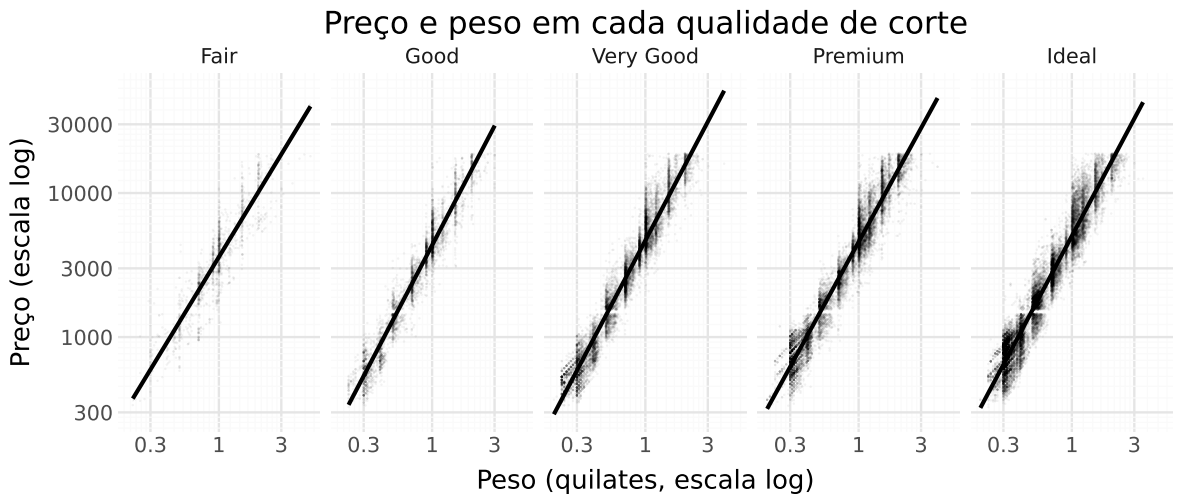


Com quase 54 mil diamantes, os pontos se sobrepõem bastante, então usei transparência e pontos pequenos para que a densidade aparecesse. Na escala original a relação é curva e a dispersão aumenta junto com o peso, por isso passei os dois eixos para escala logarítmica, o que deixou a nuvem próxima de uma reta. Também acrescentei uma curva suavizada, rótulos com unidades e marcas de eixo em valores naturais. O resultado mostra uma associação positiva e forte (Spearman de 0,96): na escala log-log, cada 1% a mais de peso vem acompanhado de cerca de 1,7% a mais de preço. Há ainda um acúmulo de pontos em pesos redondos, como 0,5 e 1 quilate.

3.

```
p2 = (ggplot(df, aes("carat", "price"))
    + geom_point(alpha=0.05, size=0.6, stroke=0)
    + geom_smooth(method="lm", color="black")
    + facet_wrap("~cut", nrow=1)
```

```
    + scale_x_log10() + scale_y_log10()
    + labs(x="Peso (quilates, escala log)", y="Preço (escala log)", title="Preço e peso em ca
    + theme_minimal()
    + theme(figure_size=(7, 3)))
p2.show()
```

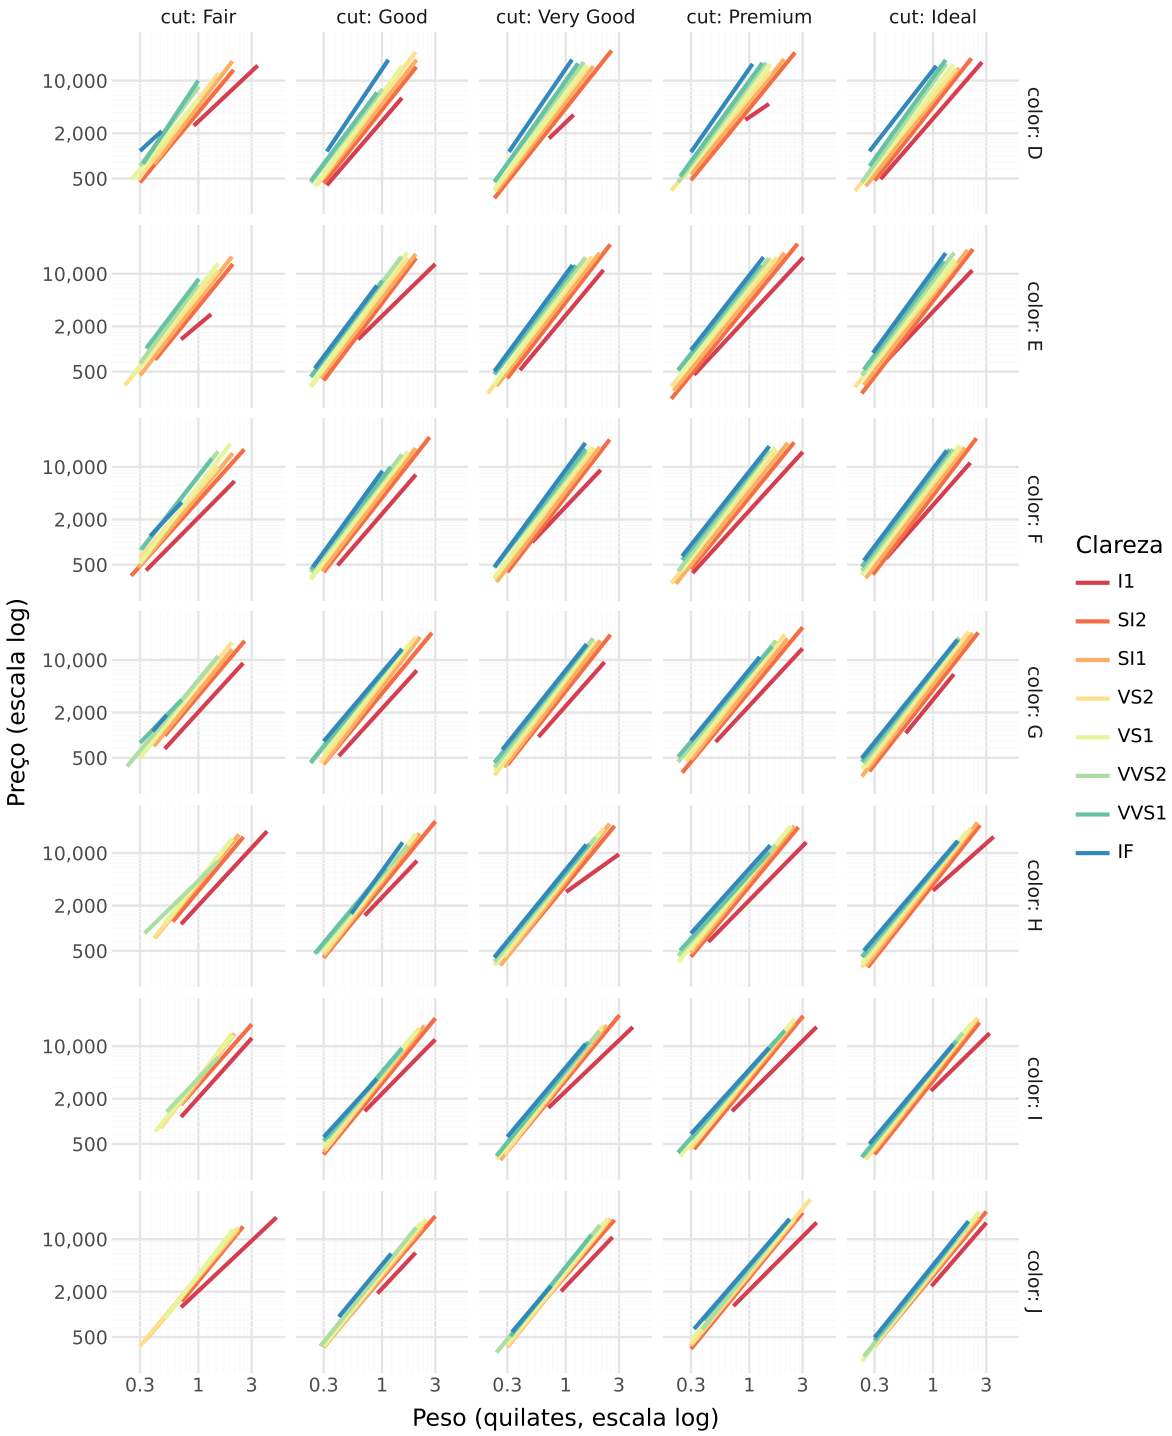


A tendência crescente aparece em todos os cortes, mas não é idêntica. As inclinações no ajuste log-log ficaram entre 1,66 e 1,74 para Good, Very Good, Premium e Ideal, enquanto o corte Fair teve crescimento mais lento (1,49) e maior dispersão. As diferenças entre os quatro melhores cortes são pequenas, o que sugere que o peso explica o preço de forma parecida em quase todos eles, e que o corte pesa menos do que se poderia esperar

4.

```
p3 = (ggplot(df, aes("carat", "price", color="clarity"))
    + geom_smooth(method="lm", se=False, size=1)
    + facet_grid("color ~ cut", labeller="label_both")
    + scale_x_log10(breaks=[0.3, 1, 3])
    + scale_y_log10(breaks=[500, 2000, 10000], labels=lambda l: [f"{round(v):,}" for v in l])
    + scale_color_brewer(type="seq", palette="Spectral")
    + labs(x="Peso (quilates, escala log)", y="Preço (escala log)", color="Clareza")
    + theme_minimal(base_size=10)
    + theme(figure_size=(7, 8.5), strip_text=element_text(size=8)))
p3.show()
```

```
C:\Users\willi\AppData\Local\R\cache\R\RETICU~1\uv\cache\ARCHIV~1\TYCMBN~1\Lib\site-
packages\plotnine\stats\stat_smooth.py:213: PlotnineWarning: Smoothing requires 2 or more poi
C:\Users\willi\AppData\Local\R\cache\R\RETICU~1\uv\cache\ARCHIV~1\TYCMBN~1\Lib\site-
packages\plotnine\stats\stat_smooth.py:213: PlotnineWarning: Smoothing requires 2 or more poi
C:\Users\willi\AppData\Local\R\cache\R\RETICU~1\uv\cache\ARCHIV~1\TYCMBN~1\Lib\site-
packages\plotnine\stats\stat_smooth.py:213: PlotnineWarning: Smoothing requires 2 or more poi
C:\Users\willi\AppData\Local\R\cache\R\RETICU~1\uv\cache\ARCHIV~1\TYCMBN~1\Lib\site-
packages\plotnine\stats\stat_smooth.py:213: PlotnineWarning: Smoothing requires 2 or more poi
C:\Users\willi\AppData\Local\R\cache\R\RETICU~1\uv\cache\ARCHIV~1\TYCMBN~1\Lib\site-
packages\plotnine\stats\stat_smooth.py:213: PlotnineWarning: Smoothing requires 2 or more poi
```



A maior dificuldade foi o número de combinações: das 280 possíveis, 276 existem nos dados, e mostrar todas com pontos deixa a figura ilegível. Além disso, os grupos são muito desiguais,

com mediana de cerca de 90 diamantes e 30 combinações com menos de 10, o que torna as retas instáveis. Diamantes pesados também são raros nas classes inferiores, então o intervalo de peso muda de um painel para outro. Por isso resumi cada grupo por uma reta e usei a cor para a clareza. A relação segue crescente em todas as configurações, mas o nível do preço muda: ao incluir cada variável no modelo log-log, o R^2 sobe de 0,933 (só peso) para 0,937 com o corte, 0,945 com a cor e 0,965 com a clareza, chegando a 0,983 com as três. A clareza é, portanto, a que mais desloca o preço para um mesmo peso, e o corte a que menos o faz. As inclinações são parecidas entre os grupos, com exceção de Fair e I1, mais baixas, e as diferenças em combinações raras devem ser lidas com cautela, pois podem refletir só ruído amostral.

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-21 03:52:18 -03"
```